FORMATO DE PROPUESTA DEL MODELO PREDICTIVO

Minería de Datos I | Proyecto de Aula: Playground

A. Identificación

Nombre del proyecto	Playground: comparador de precios de videojuegos entre tiendas digitales
Integrantes	Yorllanis Santana González; Marwin Bello Flames; Jonathan Gaviria Lara; Isaac González Martínez
Repositorio	https://github.com/Marwinyic/playground-miner-a-datos
Fecha	16 de octubre de 2026
Estado del modelo	Procedimiento ejecutado como prueba de concepto sobre un dataset público de Steam (ver secciones C y E). Aún no entrenado con datos propios de Playground.

B. Problema

¿Qué situación aborda el proyecto?

Playground compara los precios de videojuegos entre diferentes tiendas digitales para ayudar al usuario a encontrar la opción más económica. Conocer solo el precio actual no permite saber si conviene comprar ahora o esperar una oferta: los descuentos dependen de la tienda, la temporada, el historial de precios y las promociones comerciales.

¿Qué pregunta se busca responder?

¿Un videojuego tendrá al menos un descuento durante los próximos 30 días, dado su comportamiento histórico de precios hasta hoy?

¿Por qué sería útil estudiar esta situación mediante datos?

Los descuentos dejan patrones medibles (frecuencia, tiempo transcurrido desde la última oferta, profundidad del descuento, estacionalidad). Estimar su probabilidad permitiría pasar de un comparador de precios actuales a una herramienta que oriente la decisión de compra y aproveche los datos que el proyecto ya almacena en MongoDB.

C. Datos

Fuentes y enlaces

- **Dataset usado para la prueba de concepto (datos reales, públicos):** Wannigamage, D., Barlow, M., Lakshika, E. y Kasmarik, K. *Steam Games Dataset: Player count history, Price history and data about games*. Mendeley Data, V1, 2020. DOI: 10.17632/ycy3sy3vj2.1. https://data.mendeley.com/datasets/ycy3sy3vj2/1. Se utilizó únicamente la carpeta de historial de precios (PriceHistory). *Licencia: verificar en la ficha del dataset antes de redistribuir.*
- **Datos propios del proyecto:** base de datos MongoDB de Playground (videojuegos, descripciones, géneros, precios) y una primera captura de precios de Steam del 16-10-2026 exportada a CSV (ver tabla).

Número de registros y variables

	Dataset de historial (Mendeley)	Captura propia (CSV 16-10-2026)
Registros	725.268 filas diarias	244.414 filas
Juegos	1.512 archivos (1.502 usados en el modelo)	31.489 juegos en 8 países (us, ca, gb, au, br, jp, cn, de)
Variables	Date, Initialprice, Finalprice, Discount (más appid, tomado del nombre del archivo)	appid, cc, currency, initial, final, discount_pct, is_free

	Dataset de historial (Mendeley)	Captura propia (CSV 16-10-2026)
Periodo	07-04-2019 a 12-08-2020, frecuencia diaria, USD	Una sola fecha (sin dimensión temporal)

Variables relevantes

Del historial: fecha, precio inicial, precio final y porcentaje de descuento por juego y día. A partir de ellas se derivaron las variables predictoras descritas en la sección D.

Variable objetivo

descuento_proximos_30d (binaria): 1 si el juego tiene Discount > 0 en al menos uno de los 30 días posteriores a la fecha de observación; 0 en caso contrario. Se construyó a partir del historial real, sin etiquetas inventadas. Un 62,3 % de las observaciones de entrenamiento y un 51,8 % de las de prueba son positivas.

Problemas de calidad identificados

- No hay valores nulos ni registros duplicados (juego, fecha) en el historial. 10 juegos con menos de 60 días de registro se excluyeron.
- El 15,9 % de los días presenta descuento y el 96,2 % de los juegos tuvo al menos un descuento en el periodo.
- Los datos son de 2019 a 2020: no reflejan el comportamiento actual de las tiendas.
- Los 2.000 juegos originales se eligieron por mayor número de jugadores (diciembre de 2017), lo que sesga la muestra hacia títulos populares.
- La frecuencia es diaria, por lo que los cambios de precio de menos de 24 horas no aparecen.
- Solo incluye Steam y USD: no permite usar la tienda como variable. El ZIP de precios no incluye fecha de lanzamiento, por lo que la antigüedad del juego no se utilizó.
- El historial comienza el mismo día para casi todos los juegos, de modo que las variables históricas están truncadas al inicio. Solo se cubre un ciclo anual parcial.
- La captura propia del 16-10-2026 es un único corte en el tiempo: sirve como primer punto de un historial propio, pero por sí sola no permite construir la variable objetivo.

D. Modelo propuesto

Tipo de tarea	Clasificación binaria supervisada (con probabilidad estimada de descuento).
Algoritmo o técnica	Random Forest (300 árboles, mínimo 5 observaciones por hoja, clases balanceadas) como modelo principal; regresión logística como modelo interpretable de comparación.
Justificación	La pregunta exige una respuesta categórica (habrá o no descuento) y una probabilidad. Random Forest captura relaciones no lineales entre variables de historial sin requerir mucho preprocesamiento; la regresión logística aporta una referencia simple y explicable.
División prevista de los datos	División temporal (no aleatoria): entrenamiento con fechas de observación hasta el 01-12-2019 (44.407 observaciones) y prueba desde el 01-01-2020 (40.680 observaciones). Así las ventanas de 30 días no se solapan y no se usa información del futuro. Se toma una observación por juego cada 7 días y se exigen al menos 30 días de historial.

Variables predictoras

Todas se calculan solo con información disponible hasta la fecha de observación (sin fuga de información):

Variable	Descripción
discount_now / on_sale_now	Porcentaje de descuento vigente y si el juego está en oferta ese día

Variable	Descripción
initial_price / price_ratio	Precio inicial y relación precio final / precio inicial
days_since_last_disc / no_prev_discount	Días desde el último descuento (999 si no hay previo) e indicador de ausencia de descuento previo
n_disc_days_90	Días con descuento en los últimos 90 días
share_disc_hist	Proporción histórica de días con descuento
max_disc_hist / min_price_ratio_hist	Mayor descuento observado y menor relación de precio observada hasta la fecha
n_episodes_hist	Número de episodios de oferta registrados
month	Mes de la observación (estacionalidad)

Estrategia de preparación

- Reindexado diario por juego y relleno hacia adelante del precio en días sin registro; Discount faltante se toma como 0.
- No se eliminaron valores atípicos: los descuentos altos (hasta 100 %) son promociones válidas, no errores.
- La regresión logística usa estandarización dentro de un pipeline ajustado solo con el conjunto de entrenamiento; Random Forest no requiere escalado.
- Se excluyó la variable *days_observed* (días de historial) porque equivale a la fecha calendario y distorsiona la evaluación temporal.
- Variables previstas para cuando existan datos propios: tienda digital, género y antigüedad del juego.

E. Evaluación

Métricas y razón de su elección

Precisión, recall, F1, matriz de confusión y ROC-AUC. El problema es de clasificación binaria con clases casi equilibradas. La precisión indica qué parte de los avisos "habrá descuento" es correcta; el recall, cuántos descuentos reales se detectan; el F1 los resume; la matriz de confusión muestra el tipo de error; el ROC-AUC mide qué tan bien el modelo ordena los casos independientemente del umbral. Un error relevante para el usuario es recomendar esperar y que el descuento no llegue.

Modelos de referencia y resultados obtenidos

Resultados **reales** sobre el conjunto de prueba (40.680 observaciones, enero a julio de 2020), obtenidos al ejecutar el script *modelo_descuentos.py* (semilla 42):

Modelo	Precisión	Recall	F1	ROC-AUC
Referencia: siempre "sí"	0,518	1,000	0,683	-
Referencia: en oferta ahora	0,736	0,223	0,342	-
Referencia: descuento en últimos 90 días	0,551	0,906	0,685	-
Regresión logística	0,534	0,987	0,693	0,664
Random Forest	0,545	0,984	0,702	0,665

Matriz de confusión del Random Forest (umbral 0,5): verdaderos negativos 2.255; falsos positivos 17.334; falsos negativos 327; verdaderos positivos 20.764.

Interpretación

- El Random Forest mejora el F1 de la referencia "siempre sí" en solo 0,019 (0,702 frente a 0,683). El ROC-AUC de 0,665 indica una capacidad de ordenamiento modesta, algo mejor que el azar.

- Con umbral 0,5 el modelo predice "sí" casi siempre: de los 19.589 casos sin descuento posterior solo identifica 2.255. Esto limita su utilidad práctica en la versión actual.
- Las variables con mayor importancia en el Random Forest fueron el mes, la proporción histórica de días en oferta, los días con descuento en los últimos 90 días y los días desde el último descuento. Es una importancia dentro del modelo, no una prueba de causalidad.
- No se ajustó el umbral de decisión ni se probaron otros horizontes (por ejemplo, 14 días) o variables adicionales; podrían mejorar el desempeño, pero no se ha comprobado.

F. Resultado esperado

¿Qué se espera obtener?

Un modelo que, para cada videojuego, estime la probabilidad de descuento en los próximos 30 días y la muestre junto al precio actual en Playground. En esta etapa se comprobó que el procedimiento es ejecutable y que existe una señal predictiva modesta en datos reales de Steam; el siguiente paso es mejorar el modelo (umbral, horizonte, género y antigüedad) y reentrenarlo con el historial propio de Playground, que se acumulará repitiendo semanalmente la captura de precios.

¿Qué decisión podría apoyarse?

Orientar al usuario sobre si comprar ahora o esperar una posible oferta, y priorizar en la plataforma los juegos con mayor probabilidad estimada de descuento. La probabilidad es una estimación basada en patrones históricos, no una garantía; en la versión actual debería presentarse solo como referencia orientativa.

Principales limitaciones

- Desempeño modesto frente a una regla sencilla; el resultado no justifica por ahora una recomendación automática.
- Datos de 2019 a 2020, solo Steam y USD, muestra sesgada hacia juegos populares y un único ciclo anual parcial.
- El modelo no se ha entrenado con datos propios de Playground ni con varias tiendas; no se puede asegurar que los resultados se mantengan.
- Los descuentos dependen de decisiones comerciales y eventos externos que las variables disponibles no capturan.

Evidencias: script *modelo_descuentos.py* y archivo *resultados.json* (a incluir en la carpeta mineria-datos/ del repositorio).